

# WSTĘP

Przeprowadzono testy wydolności dla 183 sportowców. Oczyszczono dane z braków i wartości odstających. Wstępne cechy predyktywne:

wiek, wzrost, waga, VO₂max, VE, HRmax, RF, VO₂max\_I\_m.

Dodatkowe dane z krzywych kwasu mlekowego:

- Poziom kwasu mlekowego przy prędkościach 6, 8, 10 km/h (la\_8, la\_10).
- Tetno przy predkościach (hr 6, hr 8, hr 10).
- Charakterystyczne punkty krzywej, np. la\_min, hr\_min\_la, la\_max, hr\_max\_la.

Wyzwaniem był brak pełnych zakresów obciążeń (6–22 km/h). Dane kontekstualizowane pod kątem różnorodnych środowisk treningowych.

Użyteczność zbioru danych:

- Ocena wydolności sportowców
- Planowanie indywidualnych programów treningowych

# **ZBIÓR DANYCH**

### Dane osobowe:

Płeć, data badania, wiek, wzrost, waga, dyscyplina sportowa

## Parametry wydolności:

- AeT (próg aerobowy), AnT (próg anaerobowy), VO₂max (maksymalna wydolność tlenowa).
- VO<sub>2</sub> przy AnT (wydolność tlenowa na progu aerobowym), VE (wentylacja minutowa)
- R (wskaznik oddechowy), HRmax (maksymalne tętno), RF (Częstotliwość oddechów na minutę)
- Vo2max\_l\_m max wydolność tlenowa w przeliczeniu na masę ciała

## Tętno i poziom kwasu mlekowego przy różnych prędkościach:

hr\_X i la\_X (tętno i poziom kwasu mlekowego dla prędkości 6-22km/h)

### Strefy treningowe:

- z2 Tętno na poziomie rozwoju wytrzymałości tlenowej.
- **z3** Tętno na poziomie kształtowania mocy tlenowej (strefa mieszana).
- **z4** Tętno na poziomie progu tlenowo-beztlenowego.
- **z5** Tętno w strefie wytrzymałości beztlenowej.



# **ZBIÓR DANYCH**

## Proces oczyszczania i transformacji

- 1. Usunięcie zbędnych kolumn:
  - o date, hr\_6, la\_6, oraz dane od 16 km/h w górę.
- 2. Uzupełnienie braków:
  - Średnie wartości w kolumnach numerycznych.
- 3. Zakodowanie kolumn kategorycznych:
  - o sex, discipline, rf zakodowane jako wartości numeryczne.
- 4. Zachowanie oryginalnych wartości:
  - Dodano kolumnę discipline\_original.

## Efekty przetwarzania

- Zbiór danych stał się jednolity i gotowy do analizy.
- Umożliwiono dokładniejsze badanie anomalii przy wykorzystaniu algorytmu Isolation Forest.

# **ZBIÓR DANYCH**

															aned_											_	
nnamed: 0	sex	age	height	weight	discipline	AeT	AnT	vo2max	vo2_at	ve	r	hrmax	rf	vo2max_l_m	hr_8	la_8	hr_10 l	la_10 h	hr_12	la_12	hr_14	la_14	z2	z3	z4	z5	discipline_original
0	1	45	184	81.0	11	128	157	56.3	52.6	138.2	1.0	165	57	4561	116	4.1	133	3.2	138	3.3	149.0	3.5	121	129	149	158	running
1	0	33	171	64.0	11	171	184	52.8	47.8	113.2	3.0	197	116	3378	152	5.5	168	5.2	180	1.6	186.0	1.8	154	172	178	185	running
2	- 1	38	185	72.0	11	157	178	56.2	54.6	122.5	1.0	178	66	4044	105	1.4	128	1.2	140	1.0	152.0	1.2	138	158	167	179	running
3	- 1	37	182	81.0	25	134	176	53.3	51.9	154.9	1.5	180	95	4314	112	2.1	127	1.9	143	2.3	162.0	2.6	123	135	162	177	triathlon
4	1	40	175	72.0	11	139	158	58.7	46.7	135.8	2.0	181	63	4224	119	1.2	132	1.0	145	3.2	158.0	5.7	126	140	152	159	running
5	- 1	26	174	63.0	11	152	178	58.6	54.6	114.8	1.0	180	82	3693	119	1.4	130	1.2	142	1.9	152.0	2.0	138	153	167	179	running
6	- 1	16	178	53.0	11	171	189	65.1	62.1	136.0	1.0	193	128	3452	146	2.0	161	1.7	171	1.9	179.0	2.1	158	172	183	190	running
7	1	29	173	97.0	9	148	166	51.2	48.3	158.0	1.0	175	111	4966	132	5.5	144	4.2	153	1.9	166.0	3.6	136	149	159	167	kickboxing
8	1	34	184	78.0	11	142	171	34.1	27.4	87.1	2.0	183	8	2663	150	4.0	169	3.8	176	6.3	183.0	9.6	134	143	161	173	running
9	1	44	176	82.0	13	131	169	47.9	46.7	118.1	1.0	172	26	3673	131	2.8	146	2.7	160	2.5	172.0	3.3	119	132	152	170	running/cycling
10	1	28	176	77.0	23	159	189	50.3	46.7	147.1	2.0	196	129	3873	132	2.4	162	2.1	181	3.2	189.0	4.1	138	160	176	190	skiing
11	1	37	173	75.0	11	132	162	58.0	52.9	132.3	3.0	176	43	4348	119	7.5	134	2.9	142	3.0	156.0	3.6	121	133	149	163	running
12	0	27	175	89.0	5	128	164	40.6	35.7	118.1	1.0	175	123	3618	132	3.0	150 2	2.7	169	3.8	175.0	7.6	119	129	151	165	handball
13	1	42	170	69.0	11	141	176	58.1	56.3	119.0	2.5	182	75	4007	151	4.1	162	3.9	169	3.1	177.0	3.6	135	142	162	177	running
14	1	50	168	98.0	22	123	161	41.7	39.5	116.6	1.5	167	51	4084	127	2.3	145 2	2.8	161	3.2	167.0	3.70248447204969	115	124	144	162	running/weightlifting/cr
15	1	49	170	75.5	11	131	161	53.4	48.7	130.2	2.5	172	44	4059	130	2.7	143	2.4	155	3.3	164.0	4.2	124	132	150	162	running
16	1	25	175	73.0	15	137	175	52.7	47.8	130.8	1.5	179	94	3846	132	2.7	151 2	2.5	163	3.4	175.0	4.7	121	138	162	176	running/squash
17	1	52	176	71.0	16	137	145	48.4	46.7	103.5	1.5	148	10	3439	112	1.0	126	0.6	137	1.9	145.0	3.1	121	138	142	146	running/swiming
18	1	51	183	80.0	11	129	152	44.7	36.8	112.6	3.0	165	47	3575	138	4.6	152	4.4	161	5.2	164.0	8.2	121	130			running
19	1	23	183	77.5	0	155	193	62.2	54.5	185.4	1.0	208	104	4789	163	4.0	175	3.4	174	3.3	193.0	3.9	141	156	178	194	MMA
20	1	40	169	73.0	0	142	179	51.3	46.7	103.0	3.0	191	7	3742	131	2.4	142	1.2	160	2.4	179.0	2.8	129	143	165	180	MMA
21	1	33		73.5		136		57.9	53.4	139.8		187		4225	136		148 3		159		168.0	3.7					MMA
22	1	24		75.0		157		56.6	51.2	139.6		202	88	4245	151		161		172		182.0	3.4					MMA
23	1	37		71.0			173		53.2	137.5		180		3916	126		140		147		155.0	2.8					running
24	1	37	188			151		54.5	51.2	135.8		196		4361	151		155 3		160		181.0	3.3					running
25	1	52		75.7			174		32.1	93.6		177	40	2846	165		175		177			3.70248447204969					running
26	0	36		62.0			157		39.7	107.2		183	76	2978	137		160		175		183.0						kayaking
27	0	52	169			139		43.7	42.1		2.0	182	54	2621	139		163		174		182.0	4.0					running
28	0	24		60.0		147		43.8			1.5	193	69	2626	147		167		181		191.0	4.2					running
29	0	46		52.0		164	-	50.1			3.0	182	87	2606	166		171 6		177		182.0	3.70248447204969					running
30	0	35		59.0	0,000	138	-	46.8	36.7		1.5	184	55	2763	156		168		176		184.0	3.70248447204969					running/weightlifting
31	1	24	183			131		49.3	43.2	136.1		193	67	3944	136		155		166		179.0	4.6					football
32	1	36	179			122		63.4		165.1		169	46	5074			120 2		135		143.0	2.9					running
33	1	47		95.0	26		10000	42.8		110.9		176	16	4065	129		148 3		165		176.0	3.70248447204969					weightlifting/crossfit
34	1	56		72.0	100000	155	-	47.5		115.4		179	64	3421	120		132		150		162.0	1.8		-			running
35	1	16	183	63.0	1	148	177	53.8	45.1	111.6	1.0	193	34	4564	161	4.7	168 2	2.6	178	5.0	190.0	5.4	134	149	164	178	basketball

## **ALGORYTM ISOLATION FOREST**

### Zastosowanie i cel

- Analiza potencjalnych błędów pomiarowych, nietypowych zachowań lub przypadków zdrowotnych.
- Wyodrębnienie próbek odstających od normy w zakresie zmiennych takich jak VO2max, AeT, AnT.

## Implementacja algorytmu

- 1. Trenowanie modelu:
  - o Liczba estymatorów: 500 drzew decyzyjnych.
  - Wskaźnik anomalii (contamination): 10,3% (odpowiada liczbie oczekiwanych anomalii).
  - Losowość: Ustawiona na stałą wartość (random\_state=2137).
- Detekcja anomalii:
  - Usunięto kolumny nieistotne dla predykcji (discipline\_original).
  - Dane przekształcono przy użyciu skalera (normalizacja).
  - Wyniki detekcji:
    - anomaly = 1: Próbka zakwalifikowana jako odstająca (anomalia).
    - anomaly\_label: Przyjazny opis wyników (Anomaly lub Normal).



## **METRYKI**

Ze względu na brak dostępnych etykiet prawdziwych (ground truth), skuteczność modelu Isolation Forest została oceniona w sposób przybliżony, z wykorzystaniem dwóch podejść:

## 1. Analiza proporcji wykrytych anomalii

 Obliczono odsetek wykrytych anomalii w stosunku do liczebności całego zbioru danych, co pozwoliło ocenić skalę odstających próbek.

### 2. Wizualizacja rozkładu danych

Przeanalizowano rozkład anomalii i obserwacji normalnych w przestrzeni wybranych cech (np.
VO₂max oraz HRmax), aby zweryfikować, czy anomalie rzeczywiście odbiegają od trendu w danych.

Powyższe metody umożliwiły ogólną ocenę działania algorytmu, jednak należy podkreślić, że brak obiektywnych etykiet uniemożliwił przeprowadzenie pełnej walidacji modelu.



## **METRYKI**

## Wybrane metryki

- 1. Liczba wykrytych anomalii:
  - Pokazuje skalę odstępstw w zbiorze danych.
  - Przykład: 19 z 183 próbek oznaczone jako anomalie (10,38%).
- 2. Rozkład danych w przestrzeni cech:
  - Wizualizacja grup anomalii i danych normalnych umożliwia:
    - Identyfikację różnic pomiędzy grupami.
    - Interpretację potencjalnych przyczyn odstępstw.
- 3. Kontaminacja danych (contamination):
  - Wartość założona przy trenowaniu modelu: 10,3%.
  - Pozwala dostosować oczekiwaną liczbę anomalii do specyfiki zbioru danych.



## Wyniki eksperymentu

• Liczba próbek: 183.

Normalne: 164 (89,62%).Anomalie: 19 (10,38%).

### • Wnioski:

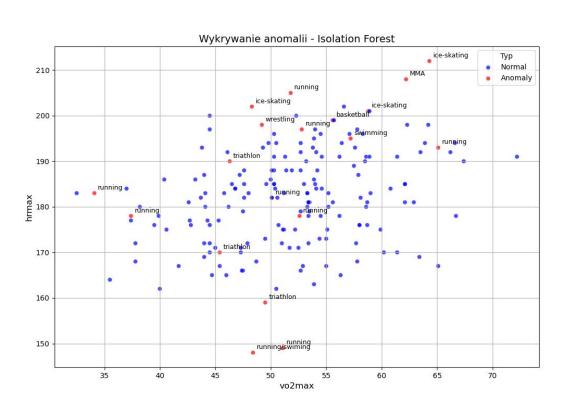
- Algorytm skutecznie zidentyfikował niewielką liczbę anomalii.
- o Dalsza analiza anomalii może ujawnić nietypowe zachowania lub stany zdrowotne.

### Podsumowanie i wnioski

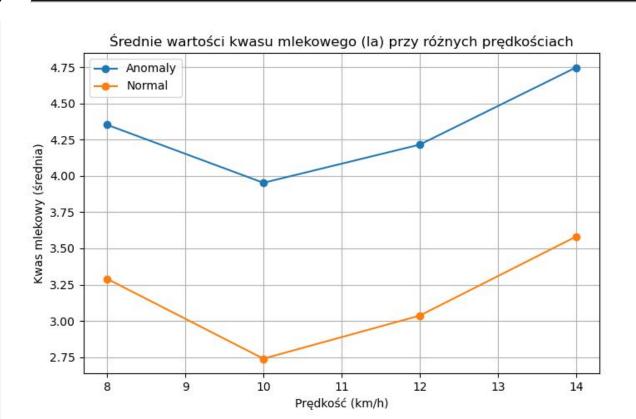
- Efektywność Isolation Forest:
  - Skuteczna identyfikacja rzadkich przypadków.
  - Możliwość praktycznego zastosowania w monitorowaniu zdrowia sportowców.
- Rekomendacje:
  - Rozszerzenie zbioru danych i testowanie innych algorytmów.
  - Szczegółowa analiza wykrytych anomalii dla dalszych badań.
- Praktyczne znaczenie:
  - Wczesne wykrywanie potencjalnych problemów zdrowotnych.
  - Lepsze dostosowanie programów treningowych.



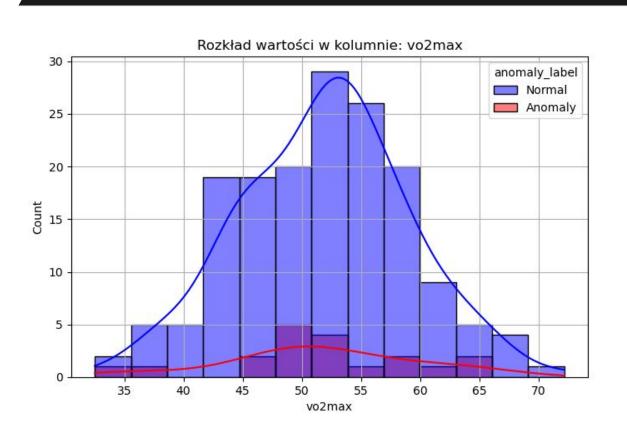
## WYKRYTE ANOMALIA DLA MAKSYMALNEGO OBCIĄŻENIA



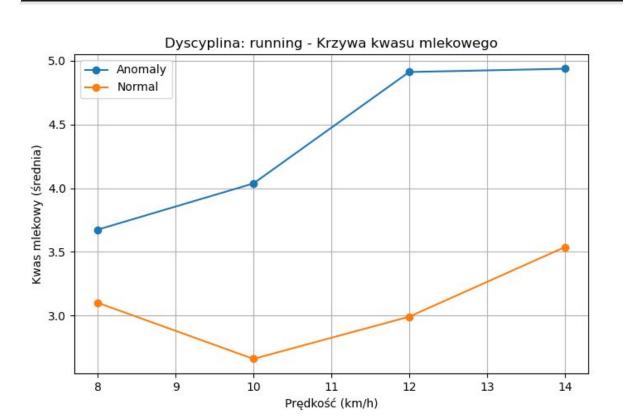
## WYKRES WARTOŚCI KWASU MLEKOWEGO PRZY RÓŻNYCH PRĘDKOŚCIACH



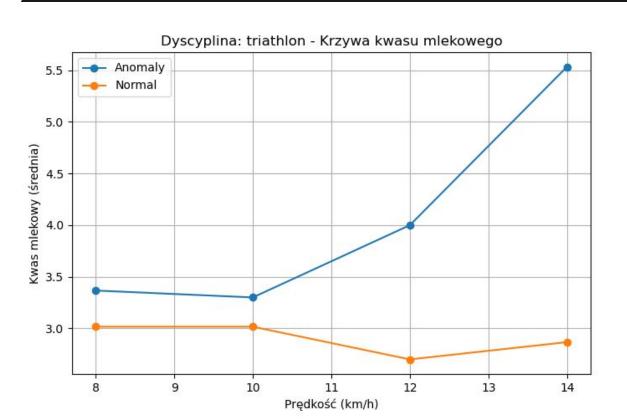
## WYKRES ROZKŁADU WARTOŚCI W KOLUMNIE DLA VO2MAX



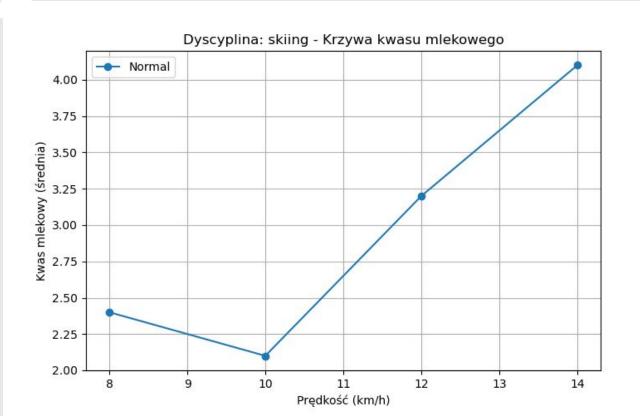
## **WYKRES KRZYWEJ MLEKOWEJ DLA RUNNING**



## **WYKRES KRZYWEJ MLEKOWEJ DLA TRIATHLON**



## **WYKRES KRZYWEJ MLEKOWEJ DLA SKIING**



## SŁOWNIK NAZW ZBIORU DANYCH

### Dane osobowe:

- Płeć (sex): Male/Female.
- Data badania (date): Data wykonania testu.
- Wiek (age): Wiek badanej osoby [lata].
- Wzrost (height): Wzrost badanej osoby [cm].
- Waga (weight): Waga badanej osoby [kg].
- Dyscyplina sportowa (discipline): Dyscyplina sportowa, np. biegacz, triathlonista.

### Wyniki testów wydolnościowych:

- AeT: Próg aerobowy [hr].
- AnT: Próg anaerobowy [hr].
- VO₂max: Maksymalna pojemność tlenowa.
- VO<sub>2</sub> at AnT: Zużycie tlenu na progu anaerobowym.
- **VE:** Wentylacja minutowa [L/min].
- R: Wskaźnik oddechowy.
- HRmax: Maksymalne tętno [uderzenia/min].
- RF: Częstotliwość oddechów [oddechy/min].
- VO₂max (L/min): Maksymalna pojemność tlenowa względem masy ciała.

### Pomiar reakcji organizmu na wysiłek:

- **Tętno (HR):** Przy różnych prędkościach (6, 8, 10, 12, 14, 16, 18, 20, 22 km/h).
- **Kwas mlekowy (LA):** Przy różnych prędkościach (8, 10, 12, 14, 16, 18, 20, 22 km/h).

### Dodatkowe strefy tętna:

- Z2: Wytrzymałość tlenowa.
- Z3: Moc tlenowa (strefa mieszana).
- **Z4:** Próg tlenowo-beztlenowy.
- Z5: Wytrzymałość beztlenowa.





# ZBIÓR DANYCH PO WYKRYCIU ANOMALII

cleaned_data (1)																														
sex	а	ige h	eight	weight	discipline	AeT	AnT	vo2max	vo2_at	ve	r	hrmax r	f vo2m	nax_l_m	hr_8	la_8	hr_10	la_10	hr_1	2 la	_12	hr_14	la_14	z2	z3	z4	<b>z</b> 5	discipline_original	anomaly	anomaly_label
- 1	1	45	184	81.0	11	128	157	56.3	52.6	138.2	1.0	165	57	4561	116	4.1	133	3.2	13	38 3.	3	149.0	3.5	121	129	149	158	running	0	Normal
0	)	33	171	64.0	11	171	184	52.8	47.8	113.2	3.0	197	16	3378	152	5.5	168	5.2	18	30 1.	6	186.0	1.8	154	172	178	185	running	1	Anomaly
1	1	38	185	72.0	11	157	178	56.2	54.6	122.5	1.0	178	66	4044	105	1.4	128	1.2	14	1.0	0	152.0	1.2	138	158	167	179	running	0	Normal
1	1	37	182	81.0	25	134	176	53.3	51.9	154.9	1.5	180	95	4314	112	2.1	127	1.9	14	3 2.	3	162.0	2.6	123	135	162	177	triathlon	0	Normal
1	1	40	175	72.0	11	139	158	58.7	46.7	135.8	2.0	181	63	4224	119	1.2	132	1.0	14	5 3.	2	158.0	5.7	126	140	152	159	running	0	Normal
1	1	26	174	63.0	11	152	178	58.6	54.6	114.8	1.0	180	82	3693	119	1.4	130	1.2	14	2 1.	9	152.0	2.0	138	153	167	179	running	0	Normal
1	1	16	178	53.0	11	171	189	65.1	62.1	136.0	1.0	193	28	3452	146	2.0	161	1.7	17	1 13	9	179.0	2.1	158	172	183	190	running	1	Anomaly
1	1	29	173	97.0	9	148	166	51.2	48.3	158.0	1.0	175	11	4966	132	5.5	144	4.2	15	3 1.	9	166.0	3.6	136	149	159	167	kickboxing	0	Normal
1	1	34	184	78.0	11	142	171	34.1	27.4	87.1	2.0	183	8	2663	150	4.0	169	3.8	17	6 6.	3	183.0	9.6	134	143	161	173	running	1	Anomaly
1	1	44	176	82.0	13	131	169	47.9	46.7	118.1	1.0	172	26	3673	131	2.8	146	2.7	16	30 2.	5	172.0	3.3	119	132	152	170	running/cycling	0	Normal
1	1	28	176	77.0	23	159	189	50.3	46.7	147.1	2.0	196	29	3873	132	2.4	162	2.1	18	31 3.:	2	189.0	4.1	138	160	176	190	skiing	0	Normal
1	1	37	173	75.0	11	132	162	58.0	52.9	132.3	3.0	176	43	4348	119	7.5	134	2.9	14	2 3.	0	156.0	3.6	121	133	149	163	running	0	Normal
0	)	27	175	89.0	5	128	164	40.6	35.7	118.1	1.0	175	23	3618	132	3.0	150	2.7	16	39 3.	8	175.0	7.6	119	129	151	165	handball	0	Normal
1	1	42	170	69.0	11	141	176	58.1	56.3	119.0	2.5	182	75	4007	151	4.1	162	3.9	16	39 3.	1	177.0	3.6	135	142	162	177	running	0	Normal
1	1	50	168	98.0	22	123	161	41.7	39.5	116.6	1.5	167	51	4084	127	2.3	145	2.8	16	31 3.	2	167.0	3.70248447204969	115	124	144	162	running/weightlifting/crossfit	0	Normal
1	1	49	170	75.5	11	131	161	53.4	48.7	130.2	2.5	172	44	4059	130	2.7	143	2.4	15	55 3.	3	164.0	4.2	124	132	150	162	running	0	Normal
1	1	25	175	73.0	15	137	175	52.7	47.8	130.8	1.5	179	94	3846	132	2.7	151	2.5	16	3 3.	4	175.0	4.7	121	138	162	176	running/squash	0	Normal
1	1	52	176	71.0	16	137	145	48.4	46.7	103.5	1.5	148	10	3439	112	1.0	126	0.6	13	37 1.3	9	145.0	3.1	121	138	142	146	running/swiming	1	Anomaly
1	1	51	183	80.0	11	129	152	44.7	36.8	112.6	3.0	165	47	3575	138	4.6	152	4.4	16	51 5.:	2	164.0	8.2	121	130	144	153	running	0	Normal
1	1	23	183	77.5	0	155	193	62.2	54.5	185.4	1.0	208	04	4789	163	4.0	175	3.4	17	4 3.	3	193.0	3.9	141	156	178	194	MMA	1	Anomaly
1	1	40	169	73.0	0	142	179	51.3	46.7	103.0	3.0	191	7	3742	131	2.4	142	1.2	16	60 2.	4	179.0	2.8	129	143	165	180	MMA	0	Normal
1	1	33	173	73.5	0	136	171	57.9	53.4	139.8	3.0	187	26	4225	136	3.6	148	3.1	15	9 2.	4	168.0	3.7	127	137	160	172	MMA	0	Normal
1	1	24	184	75.0	0	157	188	56.6	51.2	139.6	3.0	202	88	4245	151	2.4	161	2.1	17	2 2.	3	182.0	3.4	142	158	172	189	MMA	0	Normal
1	1	37	177	71.0	11	140	173	55.2	53.2	137.5	3.0	180	15	3916	126	3.4	140	1.9	14	7 2.	5	155.0	2.8	129	141	159	174	running	0	Normal
1	1	37	188	80.0	11	151	187	54.5	51.2	135.8	2.5	196	75	4361	151	4.1	155	3.9	16	0 2.	8	181.0	3.3	137	152	176	188	running	0	Normal
1		52	174	75.7	11	141	174	37.4	32.1	93.6	3.0	177	40	2846	165	4.8	175	5.7	17	7 7.	4	171.316091954023	3.70248447204969	136	142	156	175	running	0	Normal
0	)	36	158	62.0	8	132	157	48.0	39.7	107.2	3.0	183	76	2978	137	5.1	160	4.5	17	5 7.	8	183.0	3.70248447204969	125	133	149	158	kayaking	0	Normal
0		52		60.0		139		43.7	42.1	88.9		182		2621	139		163			4 3.		182.0	4.0					running		Normal
0		24	175	60.0	11	147	188	43.8	41.2	93.5	1.5		69	2626	147		167		18	31 3.		191.0	4.2					running	0	Normal
0		46		52.0	11	164		50.1	42.3	94.2		182		2606		4.8	171			7 7.		182.0	3.70248447204969					running		Anomaly
0	)	35		59.0	21	138		46.8	36.7	89.3			55	2763	156		168			6 6.		184.0						running/weightlifting		Normal
1		24		80.0				49.3	43.2	136.1		193		3944		3.5	155			66 3.		179.0	4.6					football		Normal
1		36		80.0		122		63.4	59.8	165.1			46	5074	112			2.5		35 2.		143.0	2.9					running		Normal
1		47		95.0	26	129		42.8	37.8	110.9			16	4065	129		148			55 4.		176.0		118				weightlifting/crossfit		Normal
1		56		72.0		155		47.5	45.1	115.4			64	3421	120		132			0 1.		162.0	1.8	134				runnina		Normal
1		16		63.0		148		53.8	45.1	111.6			34	4564	161		168			8 5.		190.0	5.4	134				basketball		Normal
1		27		90.0		162		54.0	48.9	150.8			62	4656	134		163			55 1.		182.0	3.4	148				basketball	-	Normal
1		16		77.0		144		61.4	56.3	181.0			92	5674	141			3.8		1 2.		181.0	3.1	132				basketball		Normal
1		33		82.0		153		53.5	51.2	132.3			59	4385	133			1.6		37 3.		177.0	4.2	139				running		Normal
0		45		65.0				47.5	37.6	108.3			73	3085	133		150			59 4.		166.0	6.2					crossfit		Normal

## **KONGO NA GICIE**

8	Merge remote-tracking branch 'origin/main'	Krzysiekigry
•	discipline summary print	Krzysiekigry
•	Add files via upload	jniesmial*
*	Add percentage calculation for anomalies and normal data	Krzysiekigry
	refactor and cleanup	Krzysiekigry
	Implemented Isolation Forest for anomaly detection and added visualization	hubert
*		hubekro193*
1	Merge branch 'main' into Jakub 🗸 origin/Jakub	hubekro193*
	inspection and data preprocesing	jniesmial*
* <		hubekro193*
*	Merge pull request #1 from hubekro193/krzysztof	hubekro193*
•	Add data shape print statements to main.py	Krzysiekigry
	Pinhance data preprocessing: remove duplicates, normalize numeric columns, and encode ⊘/data-cleaning-and	hubert
	Enhance data preprocessing: remove duplicates, normalize numeric columns, and encode categorical features	hubert
-	Load and preprocess dataset for analysis	hubert
	Initial commit	hubekro193*

